



PROCESAMIENTO DEL LENGUAJE NATURAL

MAESTRÍA EN INTELIGENCIA ARTIFICIAL


PRESENTA: MTRO. HEBER AVALOS VIVEROS

Procesamiento del lenguaje natural

¿Qué es?

El **Procesamiento del Lenguaje Natural o NLP** es una disciplina que se encuentra en la intersección de varias ciencias, tales como las Ciencias de la Computación, la Inteligencia Artificial y Lingüística. Su idea central es la de darle a las máquinas la capacidad de leer y comprender los idiomas que hablamos los humanos.

El objetivo principal del **NLP** es reducir la brecha de comunicación entre humanos y máquinas a través de conjunto de técnicas y teorías que permiten a las computadoras procesar, analizar, comprender y generar lenguaje humano (natural).



Procesamiento del lenguaje natural

Elementos

- **Reconocimiento de voz:** Convertir una palabra hablada en un conjunto de palabras. Las palabras habladas se componen de una serie de parámetros relacionados con el sentido de la audición.
- **Comprensión del lenguaje:** El objetivo de este elemento es generar un significado para las palabras habladas, y ese significado será utilizado por el siguiente elemento (gestión del diálogo).
- **Gestión del diálogo:** La tarea principal de este elemento es coordinar y mantener unidas todas las partes del sistema y los usuarios, y conectarse con otros sistemas.
- **Comunicación con sistemas externos:** como sistemas expertos, sistemas de bases de datos u otras aplicaciones informáticas.
- **Generación de respuesta:** Establecer el mensaje que el sistema debe entregar.
- **Salida de voz:** Uso de diferentes técnicas para producir el mensaje desde el sistema.

Procesamiento del lenguaje natural

Aplicaciones

- **Traducción automática:** Google Translate, DeepL.
- **Asistentes virtuales y chatbots:** Siri, Alexa, Google Assistant, chatbots de atención al cliente.
- **Análisis de sentimientos y opiniones:** Monitoreo de redes sociales, reseñas de productos.
- **Búsqueda de información y motores de búsqueda:** Google, Bing, Yahoo.
- **Resumen automático de textos:** Generar sumarios de noticias, documentos largos.
- **Reconocimiento y síntesis de voz:** Dictado a texto, lectura de textos en voz alta.
- **Corrección gramatical y ortográfica:** Grammarly, correctores integrados en procesadores de texto.
- **Extracción de información:** Identificar entidades clave (personas, lugares, fechas) en grandes volúmenes de texto.

Procesamiento del lenguaje natural

Evolución histórica


Del procesamiento simbólico y la traducción experimental a los métodos estadísticos y las redes neuronales.

Ideas tempranas de la traducción automática

En los años 30–40 surgen propuestas y patentes de sistemas que enlazan diccionarios bilingües con mecanismos mecánicos; son antecedentes de la idea de traducción por máquina, en gran parte conceptuales o muy limitados frente a la gramática real.

Alan Turing y la inteligencia lingüística

- En los 50, definió el lenguaje como estándar de oro para la IA.
- Estableció el concepto de la **máquina de niño**, donde propuso que era mejor crear una estructura básica que aprendiera de la experiencia y los datos, este es el antecedente conceptual del aprendizaje supervisado.
- Sugirió que para educar a estas máquinas se necesitaría un sistema de castigos y recompensas (feedback), lo que hoy conocemos como aprendizaje por refuerzo.



Procesamiento del lenguaje natural

Evolución histórica


Claude Shannon y la estocástica

De 1948-1951 se demostró que el lenguaje humano puede ser analizado como un sistema matemático y estadístico, y no solo como un conjunto de reglas gramaticales.

Estableció los cimientos estadísticos del procesamiento textual:

Cadenas de Markov: Modeló el texto como un proceso estocástico donde la aparición de un carácter o palabra depende probabilísticamente de los anteriores. Esta es la base de todos los correctores ortográficos y del autocompletar de hoy.

Modelos de N-gramas: El primer intento técnico por predecir palabras y cuantificar la redundancia y entropía de los lenguajes humanos. Esto permite que podamos entender mensajes aunque tengan ruido, errores tipográficos o palabras faltantes. Gracias a Shannon, el PLN puede limpiar texto y recuperar información perdida.



Procesamiento del lenguaje natural

Evolución histórica


El experimento de Georgetown e IBM

En 1954, se realiza la primera demostración pública de traducción automática corporativa del Ruso al Inglés utilizando la supercomputadora IBM 701.

Alcance: El sistema tradujo con éxito más de 60 oraciones del ruso al inglés.

Simplicidad: Aunque en su momento pareció magia, el sistema era extremadamente rudimentario. Funcionaba con solo 6 reglas gramaticales fijas y un vocabulario (lexicón) de apenas 250 palabras.

Falso optimismo: El éxito de la demo llevó a los líderes del proyecto a asegurar que la traducción automática global se resolvería en menos de 5 años.



Procesamiento del lenguaje natural

Evolución histórica

Noam Chomsky y la revolución racionalista

En 1957, se publica Syntactic Structures y asestando un golpe al enfoque estadístico/conductista. Antes se creía (gracias a Shannon) que el lenguaje se podía entender simplemente calculando probabilidades de qué palabra sigue a otra. Chomsky demostró que eso era imposible porque el lenguaje humano tiene una estructura recursiva infinita.

“Colorless green ideas sleep furiously”

Frase diseñada por Chomsky para demostrar que una oración puede ser matemáticamente sintáctica sin tener ningún sentido semántico real.

Chomsky propuso que el cerebro humano tiene un dispositivo de adquisición del lenguaje innato. En este sentido, nacen las Gramáticas Libres de Contexto (CFG) obligando a los científicos de la computación la creación de Parsers (analizadores sintácticos) que descomponen las oraciones en árboles sintácticos.

Procesamiento del lenguaje natural

Evolución histórica

El informe ALPAC y el gran colapso

Las siglas significan Automatic Language Processing Advisory Committee (Comité Consultivo sobre el Procesamiento Automático del Lenguaje). Fue un comité creado por el gobierno de los Estados Unidos en 1964 para evaluar si valía la pena seguir gastando millones de dólares en traducción automática, tras el éxito aparente del Experimento de Georgetown en 1954.

Tras dos años de estudio, el comité publicó un reporte devastador. Cancelación inmediata de casi todos los fondos de investigación gubernamentales en EE. UU. y Europa durante 10 años. Sus conclusiones se basaron en tres puntos críticos:

- Ineficiencia Económica
- Falta de calidad
- No había escasez de traductores

Procesamiento del lenguaje natural

Evolución histórica

El refugio en los "micromundos"

En 1966, ante la imposibilidad técnica de mapear el lenguaje general, la disciplina se volcó hacia los Sistemas Expertos en dominios hiper-cerrados.

ELIZA (1966)

Creado por Weizenbaum (MIT). Usaba sustituciones sencillas y expresiones regulares para emular a un psicoterapeuta Rogeriano. Demostró la fragilidad semántica del sistema.

SHRDLU (1970)

Terry Winograd diseña un entorno lógico interactivo donde un agente entendía mandatos en lenguaje natural para mover bloques tridimensionales virtuales de colores.

LUNAR (1972)

Interfaz de lenguaje de base de datos que lograba interpretar preguntas de científicos sobre la composición química de las rocas lunares traídas por el Apolo 11

Procesamiento del lenguaje natural

Evolución histórica

La revolución empirista e IBM

Hacia fines de los 80, la caída en los costos del almacenamiento y el incremento del poder de procesamiento sepultan el paradigma simbólico puro.

Durante décadas, el PLN estaba estancado porque los lingüistas no se ponían de acuerdo en todas las reglas del idioma.

- En IBM liderado por Frederick Jelinek se estableció que el lenguaje es un problema de probabilidad, no de lógica pura.
- El reconocimiento de voz y la traducción automática empezaron a ser útiles para el público, lo que atrajo de nuevo el dinero de los gobiernos y las empresas.



Procesamiento del lenguaje natural

Evolución histórica

La infraestructura del datos

Entre 1985 y 1995 ocurrió algo crítico: la comunidad científica se dio cuenta de que para que la estadística funcionara, todos debían medir sus resultados contra el mismo examen. Así nacieron los Gold Standards.

WordNet (1985): El Mapa del Significado

Desarrollado en Princeton por George Miller. Es una red ontológica léxica gigante que agrupa palabras en conjuntos de sinónimos y mapea relaciones conceptuales complejas de hiperonimia, hiponimia y meronimia.

Penn Treebank (1993): El Esqueleto Sintáctico

Mitchell Marcus coordina la anotación manual y sintáctica detallada de más de 4.5 millones de palabras del Wall Street Journal. Expertos lingüistas leyeron miles de noticias y dibujaron los árboles sintácticos de cada oración. Introdujo un conjunto de etiquetas (como NN para sustantivo, VB para verbo) que se convirtieron en el estándar universal.

Procesamiento del lenguaje natural

Evolución histórica

Los límites de la estadística tradicional

A principios de los 2000, el PLN se estancó ya que la fórmula de Shannon no fue suficiente para alcanzar la comprensión del lenguaje. En la estadística tradicional, las palabras eran tratadas como símbolos aislados (vectores discretos).

El Problema: Cada palabra es un vector con un 1 y miles de 0 (One-Hot Encoding).

Perro = [1, 0, 0]

Can = [0, 1, 0]

Avión = [0, 0, 1]

Si calculas la similitud matemática (producto punto), la distancia entre "Perro" y "Can" es la misma que entre "Perro" y "Avión".

Consecuencia: Para la máquina, no había relación semántica. No sabía que los sinónimos eran parecidos. Era un sistema de símbolos sin significado.

Procesamiento del lenguaje natural

Evolución histórica

Los límites de la estadística tradicional

Retos de la dimensionalidad: Los modelos de N-gramas (basados en Shannon) predicen la palabra basándose en las anteriores.

Sin embargo, el espacio de parámetros crece exponencialmente.

Un modelo de 2-gramas con 50,000 palabras necesita una tabla de 2,500 millones de combinaciones. En consecuencia es computacionalmente imposible almacenar y calcular todas las combinaciones posibles de palabras que un humano puede inventar.

Escasez de Datos (Data Sparsity)

Como el lenguaje es infinito (Chomsky tenía razón aquí), la mayoría de las frases correctas nunca aparecen en el entrenamiento.

Si el sistema nunca leyó la frase “el astronauta baila cumbia”, le asignaba una probabilidad de 0. En consecuencia, el sistema fallaba ante cualquier combinación creativa de palabras. Se usaban parches como el *Smoothing* (suavizado) para darles una probabilidad mínima.

Procesamiento del lenguaje natural

Evolución histórica

La era del Word Embeddings

En 2013, con la llegada de Word2Vec (Tomas Mikolov, Google), el PLN dejó de ser una ciencia de "contar" para ser una ciencia de "posicionar".

Frente al One-Hot Encoding (ceros y unos), los Embeddings proponen representar cada palabra como un vector de números reales (dimensiones). Ya no tenemos miles de ceros. Ahora tenemos vectores densos, en donde cada posición en el vector tiene un valor que capta la distancia matemática entre ellos ahora es casi cero! La máquina "entiende" que son parecidos.

tura una característica abstracta de la palabra.


Las palabras que aparecen en contextos similares terminan teniendo vectores similares. La distancia matemática entre ellos ahora es casi cero! La máquina "entiende" que son parecidos.

Perro =	[0.12, -0.5, 0.8, ...]
Can =	[0.11, -0.49, 0.79, ...]


Procesamiento del lenguaje natural

Evolución histórica


La era del Word Embeddings



Male-Female



Verb tense



Country-Capital

Procesamiento del lenguaje natural

Evolución histórica

Limitaciones del Word Embeddings

El Word Embeddings es excelente para convertir las palabras en vectores. Sin embargo, no es suficientemente potente para comprender relaciones entre ellas en una misma frase. Por lo tanto, no logra resolver los problemas de continuidad o de completado de frases.

Por ejemplo, el modelo de Word Embeddings no puede completar frases como: “Estoy armando las maletas porque me voy de _____”.

En cambio, para resolver este tipo de problemas existen los Modelos del Lenguaje. Estos son modelos de machine learning que intentan, entre otras, realizar 2 acciones:

- Predecir cuál es la siguiente palabra en función de las palabras anteriores.
- Predecir cuál es la palabra que debe ir en medio de una frase en función de las palabras anteriores y las siguientes.

Procesamiento del lenguaje natural

Evolución histórica

La era de las secuencias – RNNs

Si bien los Embeddings nos dieron el significado de las palabras, las Redes Neuronales Recurrentes nos dieron la capacidad de leer oraciones completas capturando el orden y el contexto.

El problema de los Embeddings estáticos era que modelos como Word2Vec era la falta de memoria de contexto. Por ejemplo: palabras como "Banco" (dinero) y "Banco" (asiento) tienen el mismo vector. Además, frases como "El perro muerde al hombre" y "El hombre muerde al perro" son casi idénticos porque contienen las mismas palabras.

En 2013, **la solución llegó gracias a las Redes Neuronales Recurrentes** RNN ya que introdujeron un bucle de retroalimentación. La red procesa la palabra actual pero también recibe una memoria o estado oculto de las palabras anteriores. Por primera vez, la máquina podía leer de izquierda a derecha, manteniendo un hilo conductor de lo que ya había procesado.

Procesamiento del lenguaje natural

Evolución histórica

La era de las secuencias – RNNs

El problema de las RNN, es que eran olvidadizas. Cuando la oración era muy larga, la información del principio se perdía antes de llegar al final.

La solución llegó en 1994 con las arquitecturas de LSTMs/GRUs (memoria a largo plazo)

Las Long Short-Term Memory (LSTMs) tienen puertas matemáticas que deciden qué información olvidar y qué información guardar. Permitieron que los sistemas de traducción (como el Google Translate de esa época) fueran mucho más coherentes al manejar oraciones complejas.

Sin embargo, existía un límite de procesamiento (cuello de botella), su diseño forzaba una secuencialidad obligatoria. Para procesar la palabra número 100, la red tenía que pasar primero por la 1, la 2, la 3... hasta la 99. En consecuencia, no se podían paralelizar en GPUs. Eran lentas de entrenar y no podían escalar a billones de palabras.

Procesamiento del lenguaje natural

Evolución histórica

El Big Bang del Transformer

En 2017, se elimina la necesidad de procesar el texto palabra por palabra. Se establece la paralelización, el modelo puede entrenarse con cantidades masivas de datos usando toda la potencia de las GPUs. Cada palabra en una frase analiza su relación con todas las demás palabras al mismo tiempo, sin importar la distancia. A diferencia de las LSTMs, el Transformer no "olvida" el inicio de la oración.

El cambio de paradigma

En 2018-2019, en lugar de entrenar un modelo desde cero para cada tarea, ahora se crearon modelos gigantes que primero (Pre-entrenamiento) y luego se ajustan a tareas específicas (Fine-tuning).

- **BERT (Google):** Introdujo la bidireccionalidad profunda. El modelo lee hacia atrás y hacia adelante para entender el contexto exacto
- **GPT-2 (OpenAI):** Demostró que un modelo entrenado simplemente para predecir la siguiente palabra empieza a desarrollar capacidades de redacción asombrosas.

Procesamiento del lenguaje natural

Evolución histórica

La explosión de los LLMs

IA Generativa y Modelos de Lenguaje Masivos (LLMs)

- Pasamos de modelos de millones de parámetros a modelos de billones de parámetros (GPT, Claude, Gemini).
- Al crecer tanto, los modelos empezaron a hacer cosas para las que no fueron programados: programar código, resolver acertijos lógicos y razonar paso a paso.

Resumen de la evolución histórica

- **Años 50:** Sueños y filosofía (Turing/Shannon).
- **Años 60-80:** Reglas y lógica (Chomsky/Micromundos).
- **Años 90:** Conteo y probabilidad (IBM/Estadística).
- **2013:** Geometría y vectores (Embeddings/Word2Vec).
- **2014-2016:** Memoria y secuencias (LSTMs).
- **2017-Hoy:** Transformers y LLMs (IA Generativa).

Procesamiento del lenguaje natural



Beneficios

El NLP facilita que los humanos se comuniquen y colaboren con las máquinas, al permitirles hacerlo en el lenguaje humano natural que usan todos los días. Esto ofrece beneficios en muchas industrias y aplicaciones.

- **Automatización y eficiencia operativa**
- **Análisis de datos**
- **Optimización de la experiencia de usuario**
- **Generación de contenido**

Procesamiento del lenguaje natural

Disciplinas de intersección




Procesamiento del lenguaje natural

Niveles del lenguaje

- **Fonológico:** trata de cómo las palabras se relacionan con los sonidos que representan.
- **Morfológico:** trata de cómo las palabras se construyen a partir de unas unidades de significado mas pequeñas llamadas morfemas, por ejemplo: Rápida + Mente = Rápidamente.
- **Sintáctico:** trata de cómo las palabras pueden unirse para formar oraciones, fijando el papel estructural que cada palabra juega en la oración y que sintagmas son parte de otros sintagmas.
- **Semántico:** trata del significado de las palabras y de cómo los significados se unen para dar significado a una oración, también se refiere al significado independiente del contexto, es decir de la oración aislada.
- **Pragmático:** trata de cómo las oraciones se usan en distintas situaciones y de cómo el uso afecta al significado de las oraciones. Se suele reconocer un subnivel recursivo: discursivo, que trata de cómo el significado de una oración se ve afectado por las oraciones inmediatamente anteriores.

Procesamiento del lenguaje natural



Procesamiento del lenguaje natural

Enfoques del NLP

El Procesamiento del Lenguaje Natural se divide en tres enfoques diferentes:

1. Basado en reglas
 - Utiliza el razonamiento de sentido común para las tareas de procesamiento.
 - Por ejemplo:
 - La temperatura de congelación puede provocar la muerte
 - El café caliente puede quemar la piel de las personas
 - Sin embargo, este proceso puede llevar más tiempo y requiere un esfuerzo manual.
2. Estadístico
 - Este tipo de NLP utiliza grandes cantidades de datos y pretende extraer conclusiones de ellos.
 - Para entrenar los modelos de NLP, utiliza algoritmos de aprendizaje automático.
 - Una vez completado el proceso de entrenamiento en grandes cantidades de datos, el modelo entrenado tendrá resultados positivos con la deducción.
3. Deep learning

Este es el enfoque más reciente y actualmente dominante, impulsado por los avances en redes neuronales profundas y la disponibilidad de datos y poder computacional.

Procesamiento del lenguaje natural

Problemas de ambigüedad

La ambigüedad en el lenguaje humano se refiere a la propiedad de una palabra, frase u oración de tener múltiples significados o interpretaciones posibles. Para los humanos, el contexto y el conocimiento del mundo suelen ayudar a resolver estas ambigüedades de forma casi inconsciente. Sin embargo, para las máquinas, representan un desafío significativo.

Ejemplos:

1. Vi al hombre en el parque con un telescopio.
2. El pollo está listo para comer.
3. Los niños comieron dulces y pasteles que estaban deliciosos.
4. Juan le dio un libro a Pedro. Él estaba muy contento.

A partir de ejemplos como el anterior, podemos observar que el procesamiento del lenguaje no es "determinista":

Procesamiento del lenguaje natural

Tipos de ambigüedad

1. **Ambigüedad léxica** es la que implica la ambigüedad de una sola palabra que puede tener varios significados. *Se sentó a esperar afuera del banco. (en banco como entidad o para sentarse)*
2. **Ambigüedad sintáctica** se produce cuando una frase se analiza de diferentes maneras. *Vi al hombre en el parque con un telescopio. (¿El hombre tenía el telescopio o yo lo vi a través de él?)*
3. **Ambigüedad semántica** se produce cuando, a pesar de que la sintaxis es clara y las palabras se conocen, la oración completa permite múltiples interpretaciones lógicas. *Todos los estudiantes de la maestría hablan un idioma.*
4. **Ambigüedad correferencia** surge cuando un pronombre (él, ella, lo, su) se refiere a un elemento mencionado anteriormente, pero en el texto existen múltiples entidades candidatas y la máquina no sabe a cuál apuntar. *"Juan le dio un libro a Pedro. Él estaba muy contento."*
5. **Ambigüedad pragmática** Se produce cuando el significado literal de la oración está perfectamente claro, pero la intención real del hablante depende por completo del contexto del mundo real, la ironía, el sarcasmo o el conocimiento compartido. *Un usuario le dice a un chatbot de soporte: "¡Qué gran servicio al cliente tienen!" tras esperar 4 horas en línea.*

Procesamiento del lenguaje natural

El Pipeline de procesamiento lingüístico

Para resolver las ambigüedades que acabamos de ver, la computadora no puede atacar el texto todo de un golpe. Debe descomponer el lenguaje de forma modular.

Flujo computacional:

- Entrada de texto crudo (*Raw Text*).
- Análisis morfológico: Identificar la estructura interna de las palabras (raíces y afijos).
- Etiquetado morfosintáctico: Asignar categorías gramaticales (sustantivo, verbo, adjetivo).
- Análisis sintáctico: Construir el árbol estructural de la oración.
- Análisis semántico y pragmático: Extraer el significado lógico y el contexto.

Procesamiento del lenguaje natural

Análisis Morfológico

Es la rama de la lingüística que estudia la estructura interna de las palabras y los principios que rigen la configuración de sus unidades mínimas con significado. Su objetivo es descomponer la palabra en sus partes constituyentes.

Para un ingeniero en IA, la palabra no es un bloque sólido; es una estructura armada. Si intentáramos mapear el lenguaje guardando cada palabra posible en una base de datos, el sistema colapsaría.

Por ejemplo, en español, un solo verbo regular tiene más de 40 formas conjugadas distintas. Multiplica eso por miles de verbos. El análisis morfológico resuelve este problema permitiendo que la máquina calcule la raíz y los componentes de una palabra de manera dinámica en lugar de memorizarlos.

Canto, cantas, canta, cantamos, cantan...

Cantaba, cantabas, cantábamos...

Canté, cantaste, cantó, cantamos...

Cantaré, cantarás, cantará...

Cantando, cantado...

Procesamiento del lenguaje natural

Análisis Morfológico

En lugar de guardar 40 registros, tu base de datos solo guarda 1 raíz (lexema) y una pequeña tabla de reglas fijas (sufijos flexivos).

Guardas en el lexicón: cant- (raíz que significa).

Guardas las desinencias (las reglas):

- o = [Presente, Indicativo, 1ª Persona, Singular]
- ábamos = [Copretérito, Indicativo, 1ª Persona, Plural]
- aré = [Futuro, Indicativo, 1ª Persona, Singular]

La magia en tiempo de ejecución:

Cuando el usuario escribe la frase: "Nosotros cantábamos ayer", la IA no va a buscar la palabra "cantábamos" en una lista infinita.

El analizador morfológico la parte en dos: Cantábamos -> cant (raiz) + ábamos (sufijo)

Procesamiento del lenguaje natural

Análisis Morfológico

Componentes esenciales

Lexema o raíz: Es el núcleo de la palabra. Contiene el significado conceptual o de diccionario.

Ejemplo: En la familia de palabras *niño, niñez, niñera*, el lexema es *niñ-*.

Morfemas flexivos: Son sufijos que se añaden al lexema para expresar categorías gramaticales como género, número, tiempo, modo o persona. No cambian la categoría gramatical de la palabra.

Ejemplo: En *gatos*, la *-o* aporta el morfema flexivo de género masculino y la *-s* el de número plural. El término sigue siendo un sustantivo.

Morfemas derivativos (afijos): Son prefijos o sufijos que, al unirse al lexema, crean una palabra completamente nueva y muchas veces cambian su categoría gramatical.

Ejemplo: Nación (Sustantivo) + *-al* (Sufijo derivativo) = Nacional (Adjetivo). Nacional + *In-* (Prefijo derivativo) = Internacional.

Procesamiento del lenguaje natural

Análisis Morfológico

Técnicas enfocadas a la morfología

Stemming: Consiste en quitar y reemplazar sufijos y prefijos de la raíz de la palabra (corriendo, correr, corredor se truncan a corr-). Es veloz pero genera raíces que no son palabras reales. Ayuda a muchas aplicaciones como a clasificar textos, agrupar textos y recuperación de información.

Lematización: Un proceso más avanzado que utiliza un diccionario y reglas morfológicas para reducir una palabra a su forma canónica o lema (produce, producirá, produciendo se reducen matemáticamente al infinitivo válido producir). Lematizar implica estandarizar, desambiguar y segmentar.

Procesamiento del lenguaje natural

Análisis Morfológico

Uso de autómatas finitos para el reconocimiento morfológico

El análisis morfológico puede abordarse desde un enfoque empírico/estadístico (basado en datos y probabilidad) o desde un enfoque simbólico (basado en reglas lingüísticas rígidas).

Hoy en día, los modelos de deep learning (como los tokenizadores de los Transformers) dominan las tareas de lenguaje abierto. Sin embargo, los sistemas basados en autómatas finitos siguen siendo la ley absoluta cuando se requiere control total sin margen de error: sistemas bancarios, validadores sintácticos de compiladores y preprocesadores de lenguajes de morfología rica (español).

Procesamiento del lenguaje natural

Análisis Morfológico

Un autómata finito: Es un modelo matemático abstracto que representa un sistema con una memoria extremadamente limitada. Se compone de un número fijo de estados, transiciones (flechas) y un alfabeto de entrada.

Su única misión en la vida es procesar una cadena de símbolos carácter por carácter, moviéndose entre estados. Si al terminar de leer la cadena la máquina se detiene en un estado final o de aceptación, significa que la cadena es válida para el sistema.

Por ejemplo: Imagina que es un mapa de carreteras muy estricto. Si no hay una carretera (transición) con la letra que sigue, la máquina choca (cae en estado de error) y rechaza la palabra.

Procesamiento del lenguaje natural

Análisis Morfológico

¿Cómo se aplica un autómata a la morfología?

En el análisis morfológico, los estados representan el progreso de la lectura de una palabra y las transiciones son las letras del idioma.

Ejemplo: Validar "gato", "gatos", "gata", "gatas"

Un solo autómata puede validar las 4 variantes compartiendo la misma raíz (gat-):

- *Reconoce el lexema base*
- *Género masculino (este estado acepta gato)*
- *Número plural (este estado acepta gatos)*
- *Género femenino (este estado acepta gata)*
- *Número plural*

Solo funciona como un corrector ortográfico elegante. Te dice si "gatas" existe (True), pero no le puede decir al programa principal qué significa la "a" o la "s".

Procesamiento del lenguaje natural

Análisis Morfológico

Análisis morfológico basado en transductores de estados finitos

Para resolver la limitación del autómata clásico, la lingüística computacional adoptó el transductor de estados finitos.

Este enfoque ya no solo lee una cadena; tiene dos cintas. Una cinta de entrada (lo que el usuario escribe) y una cinta de salida (los metadatos morfológicos que la IA genera).

Considerando el mismo flujo que gatos, cuando lee la palabra carácter por carácter en la superficie, va escribiendo en la salida su análisis abstracto:

Entrada: g-a-t-o-s -> transductor -> Salida: gato + N + Masc + plur

Si el usuario escribe "Las gatas corren" o "El gato corre", el transductor limpia el texto y le entrega a la siguiente capa de la IA (el analizador sintáctico o semántico) una estructura limpia:

"Sustantivo(gato, Fem, Plur) + Verbo(correr, 3ªPersona, Plur)"

"Sustantivo(gato, Masc, Sing) + Verbo(correr, 3ªPersona, Sing)"

Procesamiento del lenguaje natural

Análisis Morfológico

Análisis morfológico avanzado (implementación con lexicón y reglas ortográficas mediante transductores)

Este enfoque, divide la gramática de la ortografía. Contiene la lista de raíces (lexemas) válidas y define qué desinencias pueden unirse a ellas. Solo le importa la estructura legal de la palabra. No tiene conocimiento de reglas ortográficas.

Al separar el Lexicón de las Reglas Ortográficas, resuelves el problema de "*busqué*":

- Ve la palabra "**busqué**", detecta la secuencia **qu + é**, y sabe por una regla matemática universal del español que esa combinación equivale a tener la raíz original **c + é**.
- Entonces, este filtro intercepta la palabra y en su cinta intermedia escribe "**buscé**".
- Ahora sí, esa cadena limpia entra al Lexicón, el cual reconoce inmediatamente la raíz **busc-** (del lema buscar) y el sufijo **-é**.

Procesamiento del lenguaje natural

Análisis Morfológico

Fundamento lingüístico

En español, la letra **c** es caprichosa porque tiene dos sonidos (fonemas) dependiendo de la vocal que tenga a la derecha:

Suena fuerte (como /k/) antes de: **a, o, u** (*casa, cosa, cuna*).

Suena suave (como /s/) antes de: **e, i** (*cero, cine*).

Cuando conjugas el verbo **Buscar**, el sonido del lexema base es fuerte (/bus-k/).

Si lo conjugas en presente para "él", añades una a: *Busc-a*. La c mantiene su sonido fuerte de forma natural.

Pero si lo conjugas en pasado para la primera persona ("yo"), el sufijo gramatical es una **é**. Si simplemente pegaras las piezas como un programador perezoso, escribirías **buscé**.

El problema: Por las reglas de la RAE, "*buscé*" se pronunciaría "*bus-sé*" o "*bus-thé*". ¡Se destruiría el sonido original del verbo!

Para mantener el sonido fuerte (/k/) antes de una letra e, la ortografía del español estipula que obligatoriamente se debe sustituir la c por el dígrafo qu. Por lo tanto, busc- muta a busqu-.

Procesamiento del lenguaje natural

Análisis Morfológico

Sonido de las letras



Opciones para implementar reglas morfológicas

Descarga directa mediante librerías de NLP

- Librerías de NLP (spaCy / NLTK)
- Descarga de compiladores de estados finitos
- Generación de reglas propias

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Categorías Morfosintácticas o Gramaticales

Antes de que una computadora pueda etiquetar, necesita saber cuáles son las etiquetas disponibles. Las categorías morfosintácticas (también conocidas como *Part-of-Speech* o POS) son las clasificaciones funcionales de las palabras en un idioma.

Tradicionalmente, en la lingüística del español manejamos 9 categorías gramaticales principales (Sustantivo, Verbo, Adjetivo, Pronombre, Determinante, Adverbio, Preposición, Conjunción e Interjección). Sin embargo, en el PLN industrial, usar solo 9 etiquetas es demasiado vago para un algoritmo. Los sistemas informáticos utilizan conjuntos de etiquetas llamados.

Tagsets

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Tagsets Estándar

Penn Treebank Tagset: Diseñado originalmente para el inglés, consta de 36 a 45 etiquetas específicas. Por ejemplo, no solo etiqueta algo como "Verbo", sino que distingue si es verbo en infinitivo (VB), en pasado (VBD) o en gerundio (VBG). <https://www.sketchengine.eu/penn-treebank-tagset/>

EAGLES Tagset: Es un sistema jerárquico para el idioma en español. Usa una estructura alfanumérica donde cada posición indica una característica gramatical específica: <https://www.cs.upc.edu/~nlp/tools/parole-sp.html#%C3%ADndice>

- **N** (Sustantivo): [Tipo] [Género] [Número]
- **V** (Verbo): [Tipo] [Modo] [Tiempo] [Persona] [Número]
- **A** (Adjetivo): [Tipo] [Grado] [Género] [Número]
- **D** (Determinante): [Tipo] [Género] [Número]
- **P** (Pronombre): [Tipo] [Persona] [Género] [Número] [Caso]

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Universal Dependencies (UD)

Es un proyecto comunitario internacional que nace ante la necesidad crítica de estandarizar el análisis morfosintáctico a lo largo de todos los idiomas del mundo, eliminando las barreras de los antiguos catálogos regionales y permitiendo que una computadora procese cualquier lengua bajo las mismas reglas lingüísticas.

Aunque a nivel global coexisten cientos de colecciones de datos especializadas (llamadas *treebanks*), el eje central que unifica el estándar de forma abierta y colaborativa es la organización oficial de **Universal Dependencies en GitHub** [<https://universaldependencies.org/#language->].

En términos generales, su funcionamiento se basa en desglosar cada oración palabra por palabra para construir un objeto estructurado en la memoria de la computadora; allí, mediante un sistema universal de claves y valores (tablas hash), se le asigna a cada elemento una categoría gramatical fija.

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

El enfoque EAGLES

El sistema europeo [EAGLES](#) utiliza códigos posicionales compactos de texto. Cada letra de la etiqueta tiene un significado fijo según su posición. Si guardamos la palabra "*canciones*" en un software que usa el estándar EAGLES, la tabla hash resultante se vería así:

json

```
{  
  "palabra": "canciones",  
  "lema": "canción",  
  "tag_eagles": "NCFP000"  
}
```

¿Qué significa NCFP000 internamente?

El sistema lee la etiqueta posición por posición:

N: Sustantivo (*Noun*)

C: Común

F: Femenino

P: Plural

000: Casillas vacías para rasgos que no aplican a esta palabra

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

El Enfoque Penn Treebank (Inglés)

Fue diseñado para el inglés norteamericano. Como el inglés no divide los sustantivos en masculino o femenino, su catálogo de etiquetas es plano y mucho más simple; no necesita códigos posicionales largos. Si guardamos la palabra "*songs*" bajo este enfoque, la tabla hash en la memoria RAM se vería así:

json

```
{  
  "word": "songs",  
  "lemma": "song",  
  "tag_treebank": "NNS"  
}
```

¿Qué significa NNS internamente?

Una etiqueta directa y atómica del catálogo fijo de EE.UU:

NNS: Sustantivo, plural (*Noun, plural*).

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

El enfoque UD

Rompe las barreras del idioma. En lugar de usar códigos misteriosos como NCFP000 o NNS, utiliza sub-tablas hash con nombres explícitos y estandarizados que funcionan exactamente igual para cualquier idioma del planeta, ya sea español, inglés, alemán o chino.

Caso en español ("canciones")

```
{  
  "form": "canciones",  
  "lemma": "canción",  
  "upos": "NOUN",  
  "feats": {  
    "Gender": "Fem",  
    "Number": "Plur"  
  }  
}
```

Caso en inglés ("songs")

```
{  
  "form": "songs",  
  "lemma": "song",  
  "upos": "NOUN",  
  "feats": {  
    "Number": "Plur"  
  }  
}
```

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

El enfoque UD

Si estás procesando un documento que contiene texto en diferentes idiomas, se puede implementar dos opciones:

1) Por tokens de texto: cada palabra se convierte en un objeto hash consecutivo, sin importar su lenguaje.

```
[
  { "id": 1, "form": "Las", "lemma": "el", "upos": "DET", "feats": { "Definite": "Def", "Gender": "Fem", "Number": "Plur" } },
  { "id": 2, "form": "canciones", "lemma": "canción", "upos": "NOUN", "feats": { "Gender": "Fem", "Number": "Plur" } },
  { "id": 3, "form": "are", "lemma": "be", "upos": "AUX", "feats": { "Mood": "Ind", "Tense": "Pres", "VerbForm": "Fin" } },
  { "id": 4, "form": "beautiful", "lemma": "beautiful", "upos": "ADJ", "feats": null }
]
```

2) Por diccionario multilingüe: puedes usar el idioma como una clave de nivel superior dentro de la misma tabla hash.

```
{
  "concept_id": "concept_0987", "languages": {
    "es": { "form": "canciones", "lemma": "canción", "upos": "NOUN", "feats": { "Gender": "Fem", "Number": "Plur" } },
    "en": { "form": "songs", "lemma": "song", "upos": "NOUN", "feats": { "Number": "Plur" } },
    "it": { "form": "canzoni", "lemma": "canzone", "upos": "NOUN", "feats": { "Gender": "Fem", "Number": "Plur" } }
  }
}
```

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Problemas de ambigüedad

¿qué pasa cuando una palabra tiene más de una etiqueta válida en el diccionario?

- **Cantamos** en Presente de Indicativo su etiqueta es: **VMIP1P0**
- **Cantamos** en Pretérito Perfecto Simple (pasado) su etiqueta es: **VMIS1P0**

Si la computadora solo se queda con el análisis morfológico de las tablas, se congela porque tiene dos opciones válidas para un mismo token. ¿Cómo sabe la IA si nos referimos a hoy o a ayer?

Además, imagina la oración en español: "El vino a comprar vino".

- El primer **vino** es un **Verbo** (del verbo venir).
- El segundo **vino** es un **Sustantivo** (la bebida).

Si el sistema solo tuviera una tabla hash estática, vería la palabra "vino" y no sabría cuál etiqueta elegir porque ambas opciones existen en su diccionario.

VERBOS			
Pos.	Atributo	Valor	Código
1	Categoría	Verbo	V
2	Tipo	Principal	M
		Auxiliar	A
3	Modo	Indicativo	I
		Subjuntivo	S
		Imperativo	M
		Condicional	C
		Infinitivo	N
		Gerundio	G
		Participio	P
4	Tiempo	Presente	P
		Imperfecto	I
		Futuro	F
		Pasado	S
5	Persona	Primera	1
		Segunda	2
		Tercera	3
6	Número	Singular	S
		Plural	P
7	Género	Masculino	M
		Femenino	F

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Etiquetado morfosintáctico basado en modelos ocultos de Markov (HMM)

¿Cómo funciona en términos generales?

Un Modelo Oculto de Markov se basa en dos tipos de probabilidades que ha calculado previamente leyendo millones de textos de entrenamiento:

1. **Probabilidad de emisión** (¿Qué tan común es la palabra?): Es la probabilidad de que una categoría gramatical específica "emita" una palabra concreta.
Ejemplo: Si tengo la etiqueta Sustantivo, ¿qué probabilidad hay de que la palabra emitida sea "vino"? Es alta. Si tengo la etiqueta Verbo, ¿qué probabilidad hay de que sea "vino"? Es un poco más baja.
2. **Probabilidad de transición** (¿Qué palabra sigue después de cuál?): Es la probabilidad de pasar de una categoría gramatical a otra en una secuencia. Esto mide la estructura del idioma.
Ejemplo: En español, la probabilidad de que después de un Pronombre ("El") venga un Verbo ("vino") es muy alta. Pero la probabilidad de que después de un Pronombre venga un Sustantivo ("El vino a..." como bebida inicial sin artículo) o que después de la palabra "comprar" venga otro verbo conjugado en pasado es muy baja.

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Etiquetado morfosintáctico basado en modelos ocultos de Markov (HMM)

Para este tipo de problemas de ambigüedad se emplea un algoritmo matemático llamado **Algoritmo de Viterbi**, el cual analiza toda la cadena de la oración completa. Suma y multiplica las probabilidades de transición y emisión, y elige el camino secuencial más lógico.

Escenario A: "Hoy cantamos en el teatro"

El HMM analiza la palabra anterior: "**Hoy**" (Adverbio de tiempo presente).

El sistema calcula las probabilidades de transición matemática:

¿Qué tan probable es que después de un Adverbio de tiempo presente venga un Verbo en Presente (VMIP1P0)?

90% (Muy alta).

¿Qué tan probable es que después de un Adverbio de tiempo presente venga un Verbo en Pasado (VMIS1P0)?

5% (Muy baja, sería un error como "Hoy cantamos ayer").

Ganador: El HMM elige con total seguridad la etiqueta de presente VMIP1P0.

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Etiquetado morfosintáctico basado en modelos ocultos de Markov (HMM)

Para este tipo de problemas de ambigüedad se emplea un algoritmo matemático llamado **Algoritmo de Viterbi**, el cual analiza toda la cadena de la oración completa. Suma y multiplica las probabilidades de transición y emisión, y elige el camino secuencial más lógico.

Escenario B: "Ayer cantamos en el teatro"

El HMM analiza la palabra anterior: "**Ayer**" (Adverbio de tiempo pasado).

El sistema vuelve a calcular las transiciones:

¿Adverbio de pasado -> Verbo en Presente? **5%**.

¿Adverbio de pasado -> Verbo en Pasado (VMIS1P0)? **92%**.

Ganador: El HMM asigna la etiqueta de pasado VMIS1P0.

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Etiquetado morfosintáctico basado en modelos ocultos de Markov (HMM)

Es importante mencionar que los Modelos Ocultos de Markov son herramientas de la vieja escuela (fueron los reyes del PLN en los años 90 y 2000).

Antes (HMM): Calculaban la probabilidad mirando únicamente la palabra actual y una o dos palabras inmediatamente anteriores (Bigramas o Trigramas).

Si la pista para entender la palabra estaba 10 palabras atrás en la oración, el HMM fallaba porque su memoria era muy corta.

Ahora los modelos de machine learnign reemplazaron los HMM ya que permiten ver la oración completa hacia adelante y hacia atrás al mismo tiempo (atención bidireccional), logrando una precisión infinitamente mayor.

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Etiquetado morfosintáctico basado en aprendizaje automático

En los modelos tradicionales, las reglas de probabilidad eran muy rígidas y de "corta memoria". El Aprendizaje Automático cambia las reglas del juego porque aprende a representar las palabras y sus contextos como vectores numéricos, permitiendo que la computadora tome decisiones basadas en cientos de características simultáneas, y no solo en qué palabra va antes o después.

A lo largo de los años, este tema se ha dividido en tres grandes familias tecnológicas:

1. Modelos basados en Características Tradicionales
2. Modelos basados en Redes Neuronales Recurrentes (RNN y LSTM)
3. Modelos basados en Transformers (la era actual)

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Etiquetado morfosintáctico basado en aprendizaje automático

1. Modelos basados en Características Tradicionales

Fueron los primeros algoritmos de Machine Learning en superar a los HMM. Utilizan clasificadores como Árboles de Decisión, Máquinas de Vector de Soporte (SVM) o Campos Aleatorios Condicionales (CRF).

Cómo funcionan:

El programador "le enseña" al algoritmo qué características mirar mediante una tabla hash de rasgos:

- ¿La palabra empieza con mayúscula?
- ¿Termina en "-ón"?
- ¿La palabra anterior es un artículo?

El algoritmo entrena un modelo matemático que pesa el valor de cada pista para decidir si es sustantivo, verbo, etc.

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Etiquetado morfosintáctico basado en aprendizaje automático

2. Modelos basados en Redes Neuronales Recurrentes (RNN y LSTM)

A partir de 2014, las Redes Neuronales Profundas (Deep Learning) eliminaron la necesidad de que el humano diseñara las características a mano. Las redes tipo LSTM (Long Short-Term Memory) revolucionaron el etiquetado morfosintáctico.

Cómo funcionan:

- Tienen una "memoria interna" en forma de vector matemático.
- Procesan la oración palabra por palabra, pero van arrastrando la información del contexto de izquierda a derecha.
- Saben perfectamente si un "vino" que aparece al final de la oración depende de un contexto que se mencionó al puro principio del párrafo.

Procesamiento del lenguaje natural

Etiquetado Morfosintáctico (POS tagging)

Etiquetado morfosintáctico basado en aprendizaje automático

3. Modelos Basados en Transformers

Es la tecnología que usan herramientas como BERT, GPT o los modelos más avanzados de spaCy.

Cómo funcionan:

- Utilizan un mecanismo llamado Atención Bidireccional.
- Ya no leen la oración de izquierda a derecha de forma secuencial; leen todas las palabras al mismo tiempo.
- Analizan cómo vibra matemáticamente cada palabra en relación con absolutamente todas las demás de la oración.
- Logran una precisión morfosintáctica casi perfecta, incluso con errores ortográficos o palabras inventadas.

Procesamiento del lenguaje natural

Gramáticas para el análisis sintáctico

Ya sabemos qué es cada palabra a través de la **morfología y POS tagging**; ahora veremos cómo esas palabras se agrupan y se relacionan en la oración mediante una **sintaxis**, y después pasaremos a explicar qué significan y para qué se usan la **semántica y pragmática**.

¿Que es la sintaxis?

La sintaxis es la rama de la lingüística que estudia cómo se combinan y estructuran las palabras para formar unidades mayores con sentido completo: oraciones y frases. En el PLN, su objetivo es tomar la lista de tokens con sus etiquetas POS ([Sustantivo, Verbo, Artículo]) y construir una estructura jerárquica llamada **Árbol Sintáctico (Parse Tree)**. Este árbol demuestra de forma matemática quién le está haciendo qué a quién en la oración.

Procesamiento del lenguaje natural

Gramáticas para el análisis sintáctico

Gramáticas de estructura sintagmática

Este enfoque postula que las oraciones no son solo cadenas de palabras en fila, sino agrupaciones jerárquicas llamadas **sintagmas** (bloques de palabras que cumplen una función juntos). Se representan mediante **Reglas de Estructura de Frase (Reglas de Producción)**. El sistema descompone la Oración (O) en bloques lógicos recursivos:

- O -> SN SV (Una Oración se compone de un Sintagma Nominal seguido de un Sintagma Verbal).
- SN -> (Det) N (SAdj)(Un SN se compone de un Nombre, y opcionalmente un Determinante o un Adjetivo).
- SV -> V (SN) (SPrep)(Un Sintagma Verbal lleva un Verbo y opcionalmente un Sintagma Nominal o un SPrep).
- SPrep -> Prep SN (Un SPrep es una Preposición seguida de un SN).

Reglas Léxicas (Diccionario)

- Det -> el, la, un
- N -> gato, perro, agua, pescado
- V -> come, persigue, bebe
- SAdj -> negro, rápido
- Prep -> en, con

Procesamiento del lenguaje natural

Gramáticas para el análisis sintáctico

Estrategias del análisis sintáctico utilizando una gramática libre de contexto

Las Gramáticas Libres de Contexto (CFG) son formalismos matemáticos donde las reglas se aplican sin importar qué palabras haya alrededor. Para construir el árbol sintáctico usando una CFG, las computadoras usan dos estrategias principales:

Análisis Descendente (Top-Down): El algoritmo empieza desde el símbolo raíz (O) y empieza a expandir las reglas gramaticales hacia abajo hasta intentar coincidir exactamente con las palabras del texto. (Por ejemplo busca: "Quiero armar una oración, ¿qué piezas necesito?").

Análisis Ascendente (Bottom-Up): El algoritmo empieza leyendo las palabras del texto, busca qué reglas de bajo nivel las agrupan (Nombre, Verbo) y va construyendo el árbol hacia arriba hasta fusionar todo en el símbolo raíz (O). (Por ejemplo busca: "Tengo estas palabras, ¿qué estructura puedo armar con ellas?").

Procesamiento del lenguaje natural

Gramáticas para el análisis sintáctico

Estrategias del análisis sintáctico utilizando una gramática libre de contexto

Ejemplo práctico de las dos estrategias usando la oración: El gato come y la gramática básica anterior.

Paso	Estrategia descendente (Top-Down)	Estrategia ascendente (Bottom-Up)
Inicio	Arranca desde la raíz global del sistema: O	Arranca desde los tokens físicos: El gato come
Paso 1	Expande la raíz: Predice la estructura $O \rightarrow SN\ SV$	Asigna etiquetas POS (Léxico): Mapea los tokens a [Det] [N] [V].
Paso 2	Abre el primer bloque: Predice que $SN \rightarrow Det\ N$	Reduce el primer bloque: Detecta que Det + N forma un SN .
Paso 3	Machetea hojas (Izquierda): Compara Det con El y N con gato (Éxito)	Actualiza el estado intermedio: La estructura parcial en memoria es: SN V .
Paso 4	Abre el segundo bloque: Se mueve al SV y predice que $SV \rightarrow V$	Reduce el segundo bloque: Detecta que el token V puede convertirse en un SV .
Paso 5	Machetea hojas (Derecha): Compara V con come (Éxito).	Fusión final: Junta el SN y el SV bajo la regla madre de O .
Fin	Éxito: Partió de la hipótesis de una oración y logró llegar exactamente a las palabras del usuario.	Éxito: Agrupó los datos del usuario hasta lograr construir la raíz única del árbol sin que sobrara nada.



PROCESAMIENTO DEL LENGUAJE NATURAL

MAESTRÍA EN INTELIGENCIA ARTIFICIAL

PRESENTA: MTRO. HEBER AVALOS VIVEROS